

DOI: 10.3785/j.issn.1006-754X.2009.04.007

基于 Kriging 代理模型的改进 EGO 算法研究

王红涛, 竺晓程, 杜朝辉

(上海交通大学 机械与动力工程学院, 上海 200240)

摘 要: 代理模型是复杂工程优化设计问题的关键技术之一. 基于 Kriging 代理模型的 EGO 算法作为一种贝叶斯全局优化算法引入了 EI 函数来确定校正点, 保证了算法的全局收敛性. 首先针对原始 EGO 算法的不足之处, 提出改进 EGO 算法. 然后采用改进 EGO 算法对 4 个经典函数和 1 个工程算例进行测试. 最后从算法的收敛速度和精度两方面将不同的算法进行比较. 结果表明改进后的 EGO 算法达到原始 EGO 算法精度时所需迭代步数更少, 与基于响应面的优化算法相比在收敛速度和精度方面更具有优势. 说明该方法适应性强, 具有很高的工程实用价值.

关键词: 改进 EGO 算法; 全局优化; Kriging 模型; 试验设计方法

中图分类号: TP18

文献标识码: A

文章编号: 1006-754X(2009)04-0266-06

Research on improved EGO algorithm based on Kriging surrogate model

WANG Hong-tao, ZHU Xiao-cheng, DU Zhao-hui

(School of Mechanical and Power Engineering, Shanghai Jiaotong University, Shanghai 200240, China)

Abstract: Surrogate model is a key technology for complex engineering optimization design. EGO algorithm, a Bayesian analysis optimization algorithm based on Kriging surrogate model, makes use of the EI function to select the next sampling point to ensure the global convergence. An improved EGO algorithm was proposed due to the shortcomings of original algorithm. Four representative numerical and one engineering examples were selected to test the improved EGO algorithm's performance. Finally, comparison of the improved EGO and other algorithms was conducted from the aspect of convergence efficiency and accuracy. The results show that the improved EGO algorithm is more efficient than the original one when the optimization process reaches the same accuracy and superior to response surface optimization algorithm in accuracy and converging efficiency. The method has strong adaptability and good engineering practical value.

Key words: improved EGO algorithm; global optimization; Kriging model; experimental design method

人们受到自然界各种物理现象的启发, 提出了许多解决复杂优化问题的方法, 如遗传算法、模拟退火算法、粒子群算法和蚁群算法等等. 与传统的基于梯度的优化方法比, 上述这些算法具有很好的鲁棒性、全局性和高度并行性等特点, 在多峰值的非线性函数优化问题中得到了成功的应用. 但是这些算法的最大缺点是收敛速度慢, 需要对目标函数进行大量的评估, 如果目标函数评估方法比较耗时(如工程

优化中的 CFD 和 FEM 分析), 则计算量很大, 严重制约了其在工程中的应用. 为了克服全局优化算法的这个缺点, 人们采用了一种称为代理模型(surrogate model)的方法来代替耗时的精确模型评估. 代理模型的计算量比精确模型小得多, 同时精度也可以得到保证, 采用代理模型可以大大减少优化过程的计算量, 提高工程优化设计的效率. 常用的代理模型主要包括多项式响应面模型、人工神经网络模

收稿日期: 2009-02-09.

基金项目: 国家自然科学基金资助项目(50576052); 博士点基金资助项目(20060248036).

作者简介: 王红涛(1979—), 男, 河南周口人, 博士生, 从事叶轮机械气动分析和优化设计等研究. E-mail: amphibian@sjtu.edu.cn.

型、径向基函数模型及 Kriging 模型等, 文献[1] 中详细讨论了这些模型的优劣, 并提出 Kriging 模型具有训练样本点处无偏估计、良好的高度非线性近似能力, 非常适合作为代理模型使用. 目前 Kriging 模型在工程优化设计领域得到了广泛应用^[2].

代理模型在优化过程中的使用方式非常重要, 最常用的也是最简单的方式是以代理模型的预测值为目标函数对其寻优得到校正点, 然后把校正点用精确模型评估并把结果用以更新代理模型, 依此往复迭代直至收敛. D. L. JONES^[3] 指出这种选择校正点的方法极易使优化过程陷入局部极值点. Kriging 模型与多项式响应面模型及人工神经网络模型最大的不同之处在于, Kriging 模型不仅提供了未知点处的预测值, 还提供了未知点处的预测标准差, 可以方便地衡量预测的精度. 针对简单地对代理模型预测值寻优确定校正点的方法所带来的局部收敛问题, M. Schonlau^[4] 提出了以 Kriging 模型为代理模型的 EGO (efficient global optimization) 算法, 该算法在选取校正点时综合考虑了 Kriging 模型的预测值和预测精度, 避免了优化过程局部收敛的风险, 并采用该算法对一组经典测试函数进行测试, 发现该算法只需要较少的迭代步数就能全局收敛. Keane 成功地将 EGO 算法应用于工程优化设计中, 结果表明该算法在收敛速度和全局寻优能力上具有很好的性能^[5].

本文先简单介绍 Kriging 方法的基本理论, 然后针对原始 EGO 算法的不足之处提出改进 EGO 算法, 最后应用改进 EGO 算法对一些经典的算例进行测试, 测试结果表明改进后的 EGO 算法在保持了原始 EGO 算法全局收敛性的基础上收敛速度得到了提升, 具有很高的工程应用价值.

1 Kriging 模型的基本理论

Kriging 模型是由南非的 G. D. Krige 于 1951 年首次提出并在地质勘查中得到成功应用, 它的进一步的理论完善工作, 由法国科学家 G. Matheron 完成. J. Sacks 把 Kriging 方法用于计算机仿真试验中, 用来映射确定性计算机仿真试验的输入输出关系, 形成了基于 Kriging 模型的计算机试验设计和分析技术 (design and analysis of computer experiments, DACE).

给定一组已知的样本点集 $X = [x^1, x^2, \dots, x^n]^T$, 样本点的响应值 $Y = [y^1, y^2, \dots, y^n]^T$, 其中 $x^i (1 \leq i \leq n)$ 是 m 维向量, m 为设计变量的个数, n 为样本点个数. Kriging 模型假设系统的响应值与自变量之间的真实关系可以表示成如下的形式:

$$y(x) = f(x) + z(x), \tag{1}$$

其中, $f(x)$ 是确定性部分, 是对设计空间的全局近似, 一般 $f(x)$ 可以用一个常数 β 表示. 则式(1)可以表示为:

$$y(x) = \beta + z(x), \tag{2}$$

$z(x)$ 是一个随机过程, 代表对全局近似的背离, 它具有如下的统计特性:

$$E[z(x)] = 0, \tag{3}$$

$$\text{Var}[z(x)] = \sigma^2, \tag{4}$$

$$\text{Cov}[z(x^i), z(x^j)] = \sigma^2 R[R(x^i, x^j, \theta)] \tag{5}$$

$(1 \leq i, j \leq n),$

其中, R 为相关函数矩阵, $R(x^i, x^j, \theta)$ 为 x^i, x^j 间的相关函数, θ 为相关向量.

相关函数通常选择简单的函数, 包括高斯函数、指数函数、球函数和样条函数等. 本文选择高斯函数作为相关函数, 它具有以下的形式:

$$R(x^i, x^j, \theta) = \exp(\sum_{k=1}^m \theta_k \|x_k^i - x_k^j\|^2). \tag{6}$$

未知点 x_0 处的预测值 $y(x_0)$ 和预测标准差 $s(x_0)$ 通过如下形式给出:

$$\hat{y}(x_0) = \hat{\beta} + r^T R^{-1} (Y - f\hat{\beta}), \tag{7}$$

$$\hat{s}^2(x_0) = \hat{\sigma}^2 (1 - r^T R^{-1} r + \frac{(1 - fR^{-1}r)^2}{f^T R^{-1} f}), \tag{8}$$

其中, $\hat{\beta} = (f^T R^{-1} f)^{-1} f^T R^{-1} Y$, $\hat{\sigma}^2 = \frac{1}{m} (Y - f\hat{\beta})^T R^{-1} (Y - f\hat{\beta})$. 当 $f(x)$ 取为常数时, f 为一个长度为 n 的单位列向量. r 为未知点与样本点之间的相关函数列向量, 定义如下:

$$r(x_0)^T = R[R(x_0, x^j, \theta)]^T = [R(x_0, x^1, \theta), R(x_0, x^2, \theta), \dots, R(x_0, x^n, \theta)]^T. \tag{9}$$

在回归模型和相关函数确定后, 相关矩阵 R 以及 $\hat{\beta}, \hat{\sigma}^2$ 都依赖于相关参数向量 θ , θ 的求解成为构建 Kriging 模型的关键. θ 通常由最大似然估计方法给出, 即在 $\theta > 0$ 的情况下使 $\det(R(\theta))^{-\frac{1}{n}} \cdot \hat{\sigma}^2(\theta)$ 的值最小.

这是一个无约束的多变量寻优问题, 本文采用文献[6] 提出的小生境微种群遗传算法求解式(10) 得到最优的相关参数向量 θ 以得到最优的 Kriging 模型.

2 改进 EGO 算法

对于 M 个变量、 N 个约束的非线性优化问题可以写成一般形式:

$$\left. \begin{aligned} &\min f(\mathbf{x}), \\ &s.t: l_i \leq x_i \leq u_i \ (i = 1, 2, \cdots, M), \\ &\quad g_j(\mathbf{x}) \leq 0 \ (j = 1, 2, \cdots, N). \end{aligned} \right\} \quad (10)$$

选择代理模型预测值的最优点作为校正点的方法称为响应最优策略. 如图 1 所示, 当最初的样本点分布不均匀时, Kriging 模型的预测值在样本点稀疏的地方与真实函数值相差很大, 如果以预测值的最优点作为校正点只是使校正后的 Kriging 模型在样本点集中的区域预测精度不断提高, 在样本点稀疏区域预测精度却没有太多变化, 如果真实函数的最优值在样本点稀疏区域, 则采用最优策略选择校正点就使得优化过程陷入了局部极值点, 可见采用响应最优策略选取校正点是不合适的. 从图 2 可以看出: 在样本点集中的区域, Kriging 模型的预测标准差很小, 接近于零; 在样本点稀疏的区域, 预测标准差很大. 根据 Kriging 模型的这一特点, 为了避免采用响应最优策略确定校正点所带来的局部收敛问题, 有必要在选择校正点时综合考虑 Kriging 模型的预测值与预测标准差.




图 1 采用响应最优策略确定校正点时 Kriging 模型预测值的变化图

Fig. 1 The prediction variety of Kriging model adopting the optimal strategy to select sampled point

M. Schonlau 提出的 EGO 算法是一种贝叶斯全局优化算法, 针对式(10)表示的一般形式的优化问题, 其基本流程为:

- (1) 在设计空间中, 利用试验设计方法(DOE)生成初始样本库.
- (2) 采用 Kriging 模型分别构建设计变量与目标函数、约束函数间的近似映射关系.
- (3) 以 EI(expected improvement)函数的值为目标函数, 选择使其最大的点作为校正点.
- (4) 对校正点采用高精度初始模型评估得到校正点的响应值, 把校正点及其响应值加入样本库中.
- (5) 重复步骤(2), (3), (4)直至收敛.

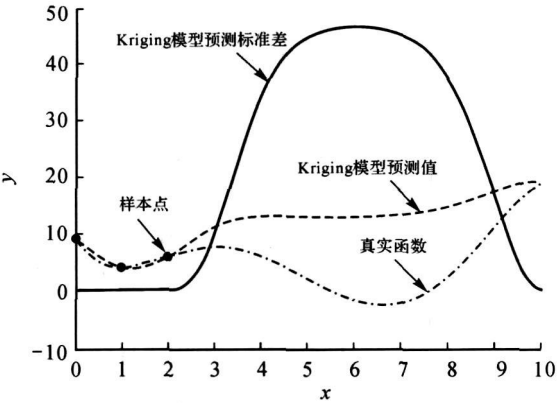


图 2 Kriging 模型拟合函数示意图
Fig. 2 The sketch map of Kriging model fitting function

其中 EI 函数定义为:

$$E[I(\mathbf{x})] = (f_{\min} - \hat{y})\Phi\left(\frac{f_{\min} - \hat{y}}{\hat{s}}\right) + \hat{s}\Psi\left(\frac{f_{\min} - \hat{y}}{\hat{s}}\right), \quad (11)$$

式(11)中, Φ 为标准正态分布函数, Ψ 为标准正态分布概率密度函数, f_{\min} 为可行域中最小的目标函数值, \hat{y} 与 \hat{s} 分别为 x 处 Kriging 模型的预测值与预测标准差. 式(11)中的第 1 项把当前最小目标函数值与预测值的差乘以预测值小于当前最小目标函数值的概率, 当预测值小于当前最小目标函数值时, 第 1 项会变得较大, 搜索的重点放在了当前最小目标函数值附近, 强化了局部搜索能力; 第 2 项是预测标准差与正态密度函数的积, 当预测精度较低及预测值与当前最小目标函数接近时, 第 2 项值较大, 把搜索重点放在了预测精度较差的区域, 强化了全局搜索能力. 所以当某点处的预测值小于当前最小值和(或)该点处的预测标准差比较大时, EI 函数值也会比较大. 采用 EI 函数确定校正点的方法同时考虑了 Kriging 模型的预测值与预测精度(预测标准差), 所以具备了很好的平衡局部和全局搜索的能力, 也同时兼顾了收敛速度和全局收敛性. LocateLi^[7] 证明了采用 EI 策略选择校正点确实能保证全局收敛. 根据上述论述, 就把式(10)转化成了

$$\left. \begin{aligned} &\max E[I(\mathbf{x})], \\ &s.t: l_i \leq x_i \leq u_i \ (i = 1, 2, \cdots, M), \\ &\quad g_j(\mathbf{x}) \leq 0 \ (j = 1, 2, \cdots, N). \end{aligned} \right\} \quad (12)$$

式(12)中的 $\hat{g}_j(\mathbf{x})$ 为约束函数 $g_j(\mathbf{x})$ 的 Kriging 模型预测值. 对于式(12)中约束的处理, 原始 EGO 算法采用的是惩罚概率方法, 即把目标函数乘以约束函数的惩罚概率, 把有约束问题转化为无约束问题. M. J. Sasena 指出惩罚概率法全局收敛性较

差^[8], 并提出采用惩罚函数法来处理约束, 但是惩罚因子的大小难以选择, 要经过多次试验才能确定. 针对原始 EGO 算法的不足之处, 本文对原始 EGO 算法作了进一步的改进, EI 函数通常是多变量和多峰值函数, 原始的 EGO 算法中是采用 DIRECT 算法来对 EI 函数寻优得到校正点的, 考虑到上文提到的小生境微种群遗传算法的良好性能, 采用该算法取代 DIRECT 算法对 EI 函数寻优来得到校正点, 约束的处理采用 K. Deb 提出的无惩罚因子的惩罚函数法^[9], 其核心思想是对遗传算法的锦标赛选择因子加以改进, 即: ①如果所比较的两个解都为可行解, 则选择目标函数值较好的一个; ②如果两个解中一个为可行解, 另一个为不可行解, 则选择可行解; ③如果两个解都为不可行解, 则选择约束违反较小的一个. 经过这样的改进就弥补了原始 EGO 算法的不足. 由于对目标函数和约束函数都采用了代理模型近似, 当目标函数和约束函数的评估过程都比较耗时能够大大减少计算量.

在基于代理模型的优化算法中, 试验设计 (DOE) 是一个相当重要的环节. 采用试验设计对设计空间进行初步扫描, 以较少的试验次数得到设计空间近似的变化规律, 提供了所要构造代理模型的不同空间位置的信息, 并为代理模型提供有代表性的基础数据. 常用的试验设计方法有正交设计、拉丁超立方体设计和均匀设计等. 均匀设计由于其样本点“均匀分散”的特点, 能够以较少的样本点描述设计空间, 提供足够的设计空间的有用信息. 考虑到均匀设计方法的优点, 本文选择均匀设计来得到空间均匀分布的初始样本点.

3 测试算例与分析

在 Matlab 平台上开发了基于本文提出的改进 EGO 算法的优化设计程序, 为了验证算法的性能, 选择 4 个数值算例和 1 个工程算例作为数值仿真的对象并与文献中的结果进行分析比较.

3.1 数值算例

本文所选择的 4 个数值算例很有代表性, 例如 GP 函数在 $(-2, 2)$ 这个很小区间内, 函数值有 9 个量级上的变化, 传统的基于梯度的优化算法求解这些算例很难得到全局最优解.

(1)Goldstein-Price(GP)函数

$$\min f(x) = [1 + (x_1 + x_2 + 1)^2(19 - 14x_1 + 3x_1^2 - 14x_2 + 6x_1x_2 + 3x_2^2)] \times [30 + (2x_1 - 3x_2)^2(18 - 32x_1 + 12x_1^2 + 48x_2 - 36x_1x_2 + 27x_2^2)],$$

其中 $-2 \leq x_i \leq 2 (i = 1, 2)$. 当 $x^* = (0, -1)$ 时最小值为 3.

(2)Hartman6(H6)函数

$$\min f(x) = - \sum_{i=1}^4 c_i \exp[- \sum_{j=1}^6 \alpha_{ij} (x_j - p_{ij})^2],$$
$$\alpha_{ij} = \begin{bmatrix} 10 & 3 & 17 & 3.5 & 1.7 & 8 \\ 0.05 & 10 & 17 & 0.1 & 8 & 14 \\ 3 & 3.5 & 1.7 & 10 & 17 & 8 \\ 17 & 8 & 0.05 & 10 & 0.1 & 14 \end{bmatrix}, c_i = \begin{bmatrix} 1 \\ 1.2 \\ 3 \\ 3.2 \end{bmatrix},$$
$$p_{ij} = \begin{bmatrix} 0.1312 & 0.1696 & 0.5569 & 0.0124 & 0.8283 & 0.5886 \\ 0.2329 & 0.4135 & 0.8307 & 0.3736 & 0.1004 & 0.9991 \\ 0.2348 & 0.1451 & 0.3522 & 0.2883 & 0.3047 & 0.6650 \\ 0.4047 & 0.8828 & 0.8732 & 0.5743 & 0.1091 & 0.0381 \end{bmatrix},$$

其中 $0 \leq x_j \leq 1 (j = 1, 2, \dots, 6)$. 当 $x^* = (0.2018, 0.1500, 0.4768, 0.2753, 0.3117, 0.6573)$, 取得最小函数值为 -3.3224 .

(3)G8 函数

$$\max f(x) = \frac{\sin^3(2\pi x_1)\sin(2\pi x_2)}{x_1^3(x_1 + x_2)},$$

s. t: $g_1(x) = x_1^2 - x_2 + 1 \leq 0,$
 $g_2(x) = 1 - x_1 + (x_2 - 4)^2 \leq 0,$

其中 $0 \leq x_i \leq 10 (i = 1, 2)$. 当 $x^* = (1.2279713, 4.2453733)$ 时, 最大函数值为 0.0958250 .

(4)G9 函数

$$\min f(x) = (x_1 - 10)^2 + 5(x_2 - 12)^2 + x_3^4 + 3(x_4 - 11)^2 + 10x_5^6 + 7x_6^2 + x_7^4 - 4x_6x_7 - 10x_6 - 8x_7,$$

s. t: $g_1(x) = 2x_1^2 + 3x_2^4 + x_3 + 4x_4^2 + 5x_5 - 127 \leq 0,$
 $g_2(x) = 7x_1 + 3x_2 + 10x_3^2 + x_4 - x_5 - 282 \leq 0,$
 $g_3(x) = 23x_1 + x_2^2 + 6x_6^2 - 8x_7 - 196 \leq 0,$
 $g_4(x) = 4x_1^2 + x_2^2 - 3x_1x_2 + 2x_3^2 + 5x_6 - 11x_7 \leq 0,$

其中, $-10 \leq x_i \leq 10 (i = 1, 2, \dots, 7)$. 当 $x^* = (2.330499, 1.951372, 0.4775414, 4.365726, 0.6244870, 1.038131, 1.594227)$ 时, 函数最小值为 680.6300573 .

3.2 工程算例

以二杆构架为对象说明改进 EGO 算法在工程中的应用, 该结构在汽车、航空、结构工程中大量出现. 如图 3 所示, 杆长 $L = 2.54 \text{ m}$, 载荷 $P = 44.4528 \text{ kN}$, 最大许可应力 $\sigma_{\max} = 275.6 \text{ MPa}$, 材料的杨氏模量 $E = 206.71 \text{ GPa}$. 以构架的体积 V 为目标函数, 以构架截面参数 (l, h, t) 为设计变量, 同时满足杆件的应力约束条件, 则优化问题可以表示为式(13), 其最小值 $V^* = 0.0115351 \text{ m}^3$.

$$\begin{aligned} \min V &= 2L(2lt + 2ht - 4t^2), \\ \text{s. t } g_1 &\equiv (\sigma_1^2 + 3\tau^2) \leq \sigma_{\max}^2, \\ g_2 &\equiv (\sigma_2^2 + 3\tau^2) \leq \sigma_{\max}^2, \\ l, h &\in [6.35 \times 10^{-2} \text{ m}, 2.54 \times 10^{-1} \text{ m}], \\ t &\in [2.54 \times 10^{-3} \text{ m}, 2.54 \times 10^{-2} \text{ m}]. \end{aligned} \quad (13)$$




图 3 二杆构架结构示意图

Fig. 3 Structure of two member frame

3.3 结果分析与对比

采用改进 EGO 算法对 4 个数值算例的测试结果如表 1 所示. M. Schonlau 采用原始 EGO 算法对 GP 函数和 H6 函数进行了测试, 由表 2 可知达到收敛时改进 EGO 算法所需要的目标函数评估次数远远小于原始的 EGO 算法需要的目标函数评估次数, 而且收敛相对误差也在同一个数量级. G. Wang^[10] 采用自适应响应面优化算法测试了 GP 函数和 H6 函数, 所需的函数评估次数也大于改进后的 EGO 算法, 且收敛误差不小于改进 EGO 算法. 由于 M. Schonlau 没有对 G8 和 G9 函数进行测试, 本文选择文献[11] 中的结果进行对比. 文献[11] 采用遗传算法求解 G8 和 G9 函数, 从表 2 可以看出改进 EGO 算法所需要的目标函数评估次数远远小于文献[11] 中的次数, 而且收敛时相对误差不大于文献[11] 的量级. N. Nguyen^[12] 采用基于响应面(RSM)的优化算法对二杆构架作了测试, 收敛时目标函数值为 0.009 504 9, 改进 EGO 算法收敛时目标函数值为 0.011 559 7. 可见由于响应面模型不能准确地映射设计变量和目标变量的关系导致得到的优化结果误差很大, 而改进后的 EGO 算法得到的最优值十分接近真实最优值.

4 结 论

本文分析讨论了原始 EGO 算法的不足之处, 提出了改进 EGO 算法, 并在 Matlab 平台上开发了基于改进 EGO 算法的优化设计程序. 通过典型测试函数的对比分析, 改进后的 EGO 算法只需要很少的迭代步数就能得到最优解, 同时也保持了原始 EGO 算法的全局收敛性. 与基于响应面代理模型的

表 1 采用改进 EGO 算法数值算例的测试结果

Table 1 Optimization results of test numerical functions by applying the improved EGO algorithm

对比项	GP 函数	H6 函数	G8 函数	G9 函数
初始样本个数	16	10	10	12
收敛时迭代次数	46	44	30	74
相对误差	1.98×10^{-4}	3.6×10^{-4}	7.8×10^{-3}	8.5×10^{-4}

表 2 文献中数值算例的测试结果

Table 2 Optimizations results of test numerical functions in literatures

对比项	GP 函数 (文献[4], [10])	H6 函数 (文献[4], [10])	G8 函数 (文献[11])	G9 函数 (文献[11])
初始样本个数	21, —	51, —	—	—
收敛时 迭代次数	95, 70	124, 1248	40582	320000
相对误差	1×10^{-4} , 7×10^{-2}	6×10^{-4} , 7.2×10^{-4}	3.5×10^{-2}	3×10^{-4}

优化算法相比, 改进 EGO 算法总能保持全局收敛能力, 同时不同于进化类算法需要大量的目标函数评估. 可见本文提出的改进 EGO 算法特别适合在复杂工程系统优化设计中采用, 具有很高的工程实用价值.

参考文献:

[1] SIMPSON T W, PEPLINSKI J D, KOCH P N. Meta-models for computer-based engineering design: survey and recommendations[J]. Engineering with Computers, 2001, 17(2): 129-150.

[2] 刘克龙, 姚卫星, 穆雪峰. 基于 Kriging 代理模型的结构优化方法研究[J]. 计算力学学报, 2006, 23(3): 344-362.

LIU Ke-long, YAO Wei-xing, MU Xue-feng. Method of structural shape optimization based on Kriging model [J]. Chinese Journal of Computational Mechanics, 2006, 23(3): 344-362.

[3] JONES D L. A taxonomy of global optimization methods based on response surfaces [J]. Journal of Global Optimization, 2001, 21(4): 345-383.

[4] SCHONLAU M. Computer experiments and global optimization[D]. Waterloo: University of Waterloo, 1997.

[5] KEANE A J. Statistical improvement criteria for use in multi-objective design optimization [J]. AIAA Journal, 2006, 44(4): 879-891.

[6] XU Y, LI G, WU Z. A novel hybrid genetic algorithm using local optimizer based on heuristic pattern move

(下转第 302 页)

(2)输入与输出参数的识别是模型修正成功与否的关键,修正成功的模型可以比较准确地描述实际结构。

(3)由上述对实际试验模型结构的修正过程可以看出,距弦支穹顶结构支座越近的构件受支座约束刚度的响应影响越大。

(4)利用一般的搜索算法可以便捷地解决本文所说的一输入一输出计算模型修正问题。

参考文献:

- [1] MAMORU Kawaguchi, MASARU Abe, TATSUO Hatato, et al. Structural tests on a full-size suspend-dome structure[C]. Proceedings of IASS Symposium, Singapore, 1997: 431-438.
- [2] MAMORU Kawaguchi, MASARU Abe, IKUO Tatemi-chi. Design test and realization of “suspend-dome” system[J]. Journal of IASS, 1999, 40(131): 179-192.
- [3] 陈志华, 李 阳, 康文江. 联方型弦支穹顶研究[J]. 土木工程学报, 2005, 38(5): 34-40.
- CHEN Zhi-hua, LI Yang, KANG Wen-jiang. Analysis of lamella suspendome systems[J]. China Civil Engi-

neering Journal, 2005, 38(5): 34-40.

- [4] 崔晓强, 郭彦林. Kiewitt 型弦支穹顶结构的弹性极限承载力研究[J]. 建筑结构学报, 2003, 24(1): 74-79.
- CUI Xiao-qiang, GUO Yan-lin. Elastic ultimate capacity of kiewitt suspend-dome[J]. Journal of Building Structures, 2003, 24(1): 74-79.
- [5] 陈 功. 空间网格结构动力有限元模型修正的分析研究[D]. 上海: 同济大学土木工程学系, 2006.
- CHEN Gong. Research on FEM model updating spatial reticulated structural dynamics[D]. Shanghai: Tongji University, Department of Civil Engineering, 2006.
- [6] 徐 丽, 易伟建. 框架结构模型修正的理论与试验研究[J]. 湖南大学学报: 自然科学版, 2000, 27(2): 87-93.
- XU Li, YI Wei-jian. Theory and test research on model updating of frame structure[J]. Journal of Hunan University: Natural Sciences Edition, 2000, 27(2): 87-93.
- [7] 陈建兴. 张弦梁结构张拉过程结构性能和伺服施工过程理论[D]. 上海: 同济大学土木工程学系, 2006.
- CHEN Jian-xing. Structural performance during prestressing and theory on servo construction process of beam string structure[D]. Shanghai: Tongji University, Department of Civil Engineering, 2006.

(上接第 270 页)

- [J]. Applied Artificial Intelligence, 2001, 15(7): 601-631.
- [7] LOACATELLI M. Bayesian algorithms for one-dimensional global optimization[J]. Journal of Global Optimization, 1997, 10(1): 57-76.
- [8] SASENA M J. Flexibility and efficiency enhancements for constrained global design optimization with Kriging approximations[D]. Ann Arbor: University of Michigan, 2002.
- [9] DEB K. An efficient constraint handling method for genetic algorithms[J]. Computer Methods in Applied Mechanics and Engineering, 2000, 186(2/4): 311-338.
- [10] WANG G, DONG Z, AITCHISON P. Adaptive re-

sponse surface method—a global optimization scheme for computation-intensive design problems[J]. Journal of Engineering Optimization, 2001, 33(6): 707-734.

- [11] CHOOTINAN P, CHEN A. Constraint handling in genetic algorithms using a gradient-based repair method[J]. Computers & Operations Research, 2006, 33(8): 2263-2281.
- [12] NGUYEN N, JEON K, LEE J. The repetitive optimization design strategy using neural network and hybrid algorithm [C]. IEEE: RIVF, Ho Chi Minh, Vietnam, 2008: 42-48.